

EVALUACIÓN PARCIAL N° 3



NOMBRE DE LA EVALUACIÓN: Utilizando los principales modelos de Deep Learning.

INFORMACIÓN GENERAL:

Sigla	Nombre Asignatura	Tiempo Asignado	% Ponderación
DLY0100	Deep Learning	180 minutos	25%

AGENTE EVALUATIVO:



Heteroevaluación (docente)

TABLA DE ESPECIFICACIONES

RESULTADOS DE APRENDIZAJE	INDICADORES DE LOGRO (IL)	% PONDERACIÓN IL
RA2 Programa modelos convolucionales y recurrentes para casos de estudio asociados a datos no estructurados, donde la entrada de datos son principalmente textos, series de tiempo y secuencia de imágenes, para dar solución a problemáticas de negocio.	IL2.1 Programa una red neuronal convolucional basado en el caso planteado, comparando el rendimiento del modelo, a través del uso de las diferentes herramientas y arquitecturas disponibles que extienden las de Machine Learning.	40%
	IL2.2 Propone arquitecturas CNN, ajustando hiperparámetros y configuración de capas, para lograr un mejor rendimiento y dar solución a una problemática de predicción, clasificación, según el caso de estudio.	60%
Total		100%

INSTRUCCIONES

Indicaciones para la entrega de encargo con presentación.

- Esta evaluación se debe realizar en grupos de dos integrantes y tiene un 25% de ponderación sobre la nota final de la asignatura.
- El tiempo para desarrollar esta evaluación es de 180 minutos y se desarrollará en el taller de Alto Computo, Laboratorio de Datos.
- Los grupos deberán elaborar el encargo con presentación que constituye el primer hito en el desarrollo del examen transversal de la asignatura.
- El encargo con presentación deberá comunicar el proceso de elaboración de una red neuronal MLP, que es capaz de resolver un problema de manera óptima basándose en el caso de uso planteado para el caso semestral.
- Aplica la metodología CRISP.DM, considerando cada una de las fases.
- Para la presentación de los grupos deberán exponer en un tiempo de cinco a ocho minutos más cinco minutos de preguntas.
- La presentación deberá ser en base a una PPT donde explica el proceso de desarrollo.
- Deberá responder a las preguntas planteadas, plasmando las respuestas en la PPT de presentación.

Contexto del caso Forma C.

A continuación, se presenta el caso a ser utilizado en las tres evaluaciones sumativas y el examen transversal de la asignatura. Deberá ser capaz de implementar un proyecto de Deep Learning entrenando un modelo ajustado a partir de los datos entregados para este caso. Desarrollará el proyecto utilizando las etapas de metodología CRISP.DM, para la toma de las mejores decisiones de la ejecución del proyecto.

Para este caso el Gobierno de Chile requiere etiquetado de imágenes de distinto dominio para implementar inteligencia artificial en su página web.

Actualmente el mundo se encuentra en una era de un gran cúmulo de datos, donde muchos problemas de tomas de decisión son resueltos mejor por máquinas que por humanos, en términos de exactitud y escalabilidad. Muchos de estos datos están conformados por imágenes. En el mundo actual es necesario poder seleccionar estas imágenes y clasificarlas, detectar qué objetos la conforman, detectar estado de ánimo de una o varias personas e identificar rostros. Para realizar estas tareas se utilizan técnicas de Inteligencia Artificial. El Aprendizaje Automático es una de las ramas de la Inteligencia Artificial que tiene como objetivo crear técnicas que le permitan a las computadoras aprender, generalizando patrones a partir de conocimiento adquirido anteriormente. Dentro del Aprendizaje Automático se encuentra el Aprendizaje Activo, donde se mejora la precisión y el rendimiento de los modelos de predicción.

Para este caso utilizaremos el conjunto de datos CIFAR-10.

CIFAR-10 consta de 60000 imágenes en color de 32x32 en 10 clases, con 6000 imágenes por clase. Hay 50000 imágenes de entrenamiento y 10000 imágenes de prueba.

El conjunto de datos se divide en cinco lotes de entrenamiento y un lote de prueba, cada uno con 10000 imágenes. El lote de prueba contiene exactamente 1000 imágenes seleccionadas al azar de cada clase. Los lotes de entrenamiento contienen las imágenes restantes en orden aleatorio, pero algunos lotes de entrenamiento pueden contener más imágenes de una clase que de otra. Entre ellos, los lotes de entrenamiento contienen exactamente 5000 imágenes de cada clase.

Descargar data set desde <https://www.cs.toronto.edu/~kriz/cifar.html>.

Pauta de Evaluación

RÚBRICA EVALUACIÓN 1 PARTE GRUPAL

Tabla 1: Descripción por categoría de respuesta

Categoría	% logro	Descripción
Excelente dominio	100%	Dominio esperado para el indicador, se considera como el punto óptimo para cualificar como competente.
Buen dominio	80%	Se observan pequeñas dificultades o errores para el completo dominio del indicador.
Dominio aceptable	60%	Suficiencia de logro en el dominio del indicador, se considera como el mínimo aceptable para cualificar como competente.
Dominio insuficiente	0%	Se observan un escaso, nulo o incorrecto dominio del indicador.

Indicador de logro	Criterio de evaluación	Categoría de Respuesta				Ponderación del indicador de logro
		Excelente dominio 100%	Buen dominio 60%	Dominio aceptable 30%	Dominio insuficiente 0%	

IL2.1 Programa una red neuronal convolucional basado en el caso planteado, comparando el rendimiento del modelo, a través del uso de las diferentes herramientas y arquitecturas disponibles que extienden las de Machine Learning.	Programa una red neuronal convolucional basado en el caso planteado, comparando el rendimiento del modelo, a través del uso de las diferentes herramientas y arquitecturas disponibles que extienden las de Machine Learning.	Programa una red neuronal convolucional basado en el caso planteado correctamente, comparando el rendimiento del modelo, a través del uso de las diferentes herramientas y arquitecturas revisadas en clases.	Programa una red neuronal convolucional basado en el caso planteado correctamente, comparando el rendimiento del modelo, a través del uso de las diferentes herramientas, pero no con las arquitecturas revisadas en clases.	Programa una red neuronal convolucional basado en el caso planteado con dificultades, no comparando el rendimiento del modelo, a través del uso de las diferentes herramientas y tampoco con las arquitecturas revisadas en clases.	No programa una red neuronal convolucional basado en el caso planteado.	40%
IL2.2 Propone arquitecturas CNN, ajustando hiperparámetros y configuración de capas, para lograr un mejor rendimiento y dar solución a una problemática de	Ajusta los hiperparámetros de la red convolucional para alcanzar un nivel óptimo de generalización del modelo planteado.	Ajusta correctamente los hiperparámetros de la red convolucional para alcanzar un nivel óptimo de generalización del modelo planteado.	Ajusta parcialmente hiperparámetros de la red convolucional para alcanzar un nivel óptimo de generalización del modelo planteado.	Ajusta con dificultades los hiperparámetros de la red convolucional para alcanzar un nivel óptimo de generalización del modelo planteado.	No ajusta los hiperparámetros de la red convolucional para alcanzar un nivel óptimo de generalización del modelo planteado.	20%

predicción, clasificación, según el caso de estudio.	Mejora el desempeño de la red neuronal, justificando y explicando los ajustes y configuraciones realizadas.	Mejora correctamente el desempeño de la red neuronal, justificando y explicando los ajustes y configuraciones realizadas.	Mejora parcialmente el desempeño de la red neuronal, pero no justifica, ni explica correctamente los ajustes y configuraciones realizadas.	Mejora con dificultades el desempeño de la red neuronal, no justificando, ni explicando correctamente los ajustes y configuraciones realizadas.	No mejora el desempeño de la red neuronal.	20%
	Analiza la diferencia entre stride y pooling, y su impacto en la reducción del tamaño de los canales en cada capa.	Explica correctamente la diferencia entre stride y pooling, y su impacto en la reducción del tamaño de los canales en cada capa.	Explica parcialmente la diferencia entre stride y pooling, y su impacto en la reducción del tamaño de los canales en cada capa.	Explica con dificultades la diferencia entre stride y pooling, y su impacto en la reducción del tamaño de los canales en cada capa.	No explica correctamente la diferencia entre stride y pooling, y su impacto en la reducción del tamaño de los canales en cada capa.	20%